

# Geoestatística:

## Considerações Iniciais

É impossível saber, antes de amostrar, de que maneira os valores das variáveis irão se comportar: se dependente ou independente uma da outra.

Devido as limitações da estatística clássica e pelo fato de que muitas variáveis são heterogêneas (os atributos variam no espaço e no tempo), torna-se necessária a utilização de procedimentos estatísticos adicionais, que considerem e reflitam essas variações.

Assumindo as hipóteses exigidas pela estatística clássica, pode-se dizer que:

um **valor medido** é em parte explicado por uma **média** e em parte pela **variação do acaso**.

# Geoestatística:

## Considerações Iniciais

Os desvios dos valores em torno da média são assumidos como sendo **independentes** e com **distribuição normal de média zero e variância  $\sigma^2$**

ou seja

a **média aritmética** dos dados amostrais é adotada como sendo **bom estimador da posição central dos valores da população**.

A **média** é então tomada como estimativa da propriedade em **locais não amostrados**, tornando necessário identificar o nível de precisão dessa média como estimador, o que, na estatística clássica, é realizado por meio das **medidas de dispersão**.

Quando é verificado que **a componente residual da variância é relativamente muito grande**, o que normalmente é indicado por um **alto CV**, o experimento ficar prejudicado, sendo que **a causa pode ser a variabilidade do conjunto de dados**, assumido como homogêneo no início.

# **Geoestatística:**

## **Considerações Iniciais**

Se a **distribuição espacial das amostras é considerada**, em muitos casos, **será possível tirar vantagem da variabilidade espacial**.

Portanto a estatística clássica e a geoestatística, ou estatística espacial, se complementam. Uma não exclui a outra, e perguntas não respondidas por uma, muitas vezes podem ser respondidas pela outra.

Quando os **dados são abundantes**, os **métodos de interpolação**, em geral produzem valores semelhantes.

Os métodos tradicionais de interpolação espacial como **triangulação e método do inverso do quadrado da distância**, no caso de **dados esparsos**, possuem **limitações** na representação da variabilidade espacial, porque **desconsideram a anisotropia** e a **continuidade do fenômeno** que se quer observar.

# **Geoestatística:**

## **Considerações Iniciais**

A sequência de passos em um estudo geoestatístico envolve:

- 1) Análise exploratória dos dados para que se possa ter a compreensão da natureza espacial da variável;
- 2) Análise estrutural do conjunto de dados para determinação da correlação espacial ou continuidade dos dados;
- 3) Elaboração de estimativas por krigagem para estimar valores em pontos não amostrados.

Antes de selecionar a técnica de estimativa mais apropriada devemos responder a algumas questões básicas:

- Queremos uma estimativa global ou local?
- Nosso objetivo é estimar apenas a média ou a distribuição completa dos dados?
- Queremos estimar valores pontuais ou blocos?

**O objetivo é determinar o valor do atributo  $z$  em posições  $u$  do espaço “não amostradas”  $\rightarrow z(u)$ .**

# Geoestatística:

## Interpolação

- Atribuição de pesos para as amostras (*weighted average interpolation algorithms*).
- Pesos entre 0 e 1, sendo que o somatório dos pesos deve ser 1.
- Quanto mais perto um dado nó do grid, maior seu peso.

## Interpoladores Clássicos

*Polígonos:* define zonas/áreas de influência, sendo o peso de acordo com a área que corresponde a cada amostra;

*Inverso da distância:* valor estimado a partir de combinações lineares dos dados vizinhos, com o peso dado pela distância que separa as amostras;

*Spline:* polinomiais de uma dada ordem que melhor se ajustam aos dados de forma suavizada.

# **Geoestatística:**

## **Desvantagem dos métodos clássicos**

- Não consideram o suporte amostral;
- Não consideram o padrão de variabilidade espacial;
- Não fornecem medida de erro da estimativa.

## **Vantagem dos métodos clássicos**

- Simples;
- Intuitivos;
- Facilmente implementáveis em rotinas computacionais.

# Geoestatística:

## Estimativa por combinação linear ponderada

A ideia básica é estimarmos um atributo qualquer em uma posição usando:

$$Z^*(u) = \sum_{i=1}^n \lambda_i Z(u_i)$$

Em que:  $u$  refere-se a uma localização qualquer

$Z^*(u)$  é o valor estimado nessa localização  $u$

existem  $n$  dados  $Z(u_i)$ ,  $i = 1, \dots, n$  na circunvizinhança de  $u$

$\lambda_i$  refere-se aos pesos calculados.

*Quais os fatores que devem ser considerados para calcular os pesos?*

- Proximidade das amostras;
- Redundância entre dados amostrais;
- Anisotropia;
- Magnitude da continuidade.

# Geoestatística:

## Estimativa por combinação linear ponderada

A krigagem é um estimador linear a partir da informação disponível, em que temos  $z(u)$  posições desconhecidas e dados nas posições  $z(u_\alpha)$  como realizações da variável regionalizada em estudo.

$$Z^*(u) - \bar{X}(u) = \sum_{\alpha=1}^{n(u)} \lambda_\alpha(u) [Z(u_\alpha) - (u_\alpha)]$$

Em que:  $Z^*(u)$  = é o valor estimado;

$\bar{X}(u)$  = média do atributo  $z(u)$ ;

$\lambda_\alpha(u)$  = pesos a serem determinados.

Dessa forma, nosso objetivo é determinar os pesos de krigagem  $\lambda_\alpha(u)$ , tal que:

$$\sigma_k^2(u) = Var\{Z^*(u) - Z(u)\}$$



# **Geoestatística:**

## **Estimativa por combinação linear ponderada**

Essa variância deve ser minimizada sob a condição de não-tendenciosidade.

$$E\{Z^*(u) - Z(u)\} = 0$$

Assim a geoestatística é um conjunto de técnicas estatísticas utilizadas para analisar a variabilidade e estimar valores de uma variável de interesse.

A metodologia proposta pela geoestatística difere da proposta pela estatística clássica, basicamente, na forma de avaliar a variação dos dados.

Enquanto a estatística clássica pressupõe não haver relação entre a variação e a distância entre pontos de amostragem, isto é, as variações são aleatórias no espaço, a geoestatística considera dependência de variação com o espaço de amostragem e que, em parte, essas variações são sistemáticas.

# Geoestatística:

## Estimativa por combinação linear ponderada

A regionalização da variável é a maneira de identificar e avaliar a estrutura espacial dos atributos estudados.

Uma premissa básica é que em todas as áreas existem regiões mais ricas do que outras, para uma determinada variável.

Ou seja, o valor da variável regionalizada  $f(\mathbf{x})$  depende da posição espacial  $\mathbf{x}$ .

Na teoria das variáveis regionalizadas,  $\mathbf{Z}(\mathbf{x})$  pode ser definida como uma variável aleatória que assume diferentes valores  $\mathbf{Z}$  em função de  $\mathbf{x}$ .

O que diferencia a **krigagem** de outros métodos de interpolação é a **estimação de uma matriz de covariância espacial** que determina os **pesos** atribuídos às diferentes amostras, o **tratamento da redundância dos dados**, a **vizinhança a ser considerada** no procedimento de inferência e o **erro associado ao valor estimado**.

# Geoestatística:

## Estimativa por combinação linear ponderada

O conjunto de amostras deve ser representativo do fenômeno que se pretende estudar.

Se  $\mathbf{x}$  representa uma posição em uma, duas ou três dimensões, então o valor da variável  $\mathbf{Z}$ , em  $\mathbf{x}$ , é, dada por (Burrough, 1987):

$$Z(x) = m(x) + \varepsilon'(x) + \varepsilon''$$

onde:  $\mathbf{m(x)}$  é uma função determinística que descreve a componente estrutural de  $\mathbf{Z}$  em  $\mathbf{x}$ ;

$\varepsilon'(\mathbf{x})$  é um termo estocástico, que varia localmente e depende espacialmente de  $\mathbf{m(x)}$ ;

$\varepsilon''$  é um ruído aleatório não correlacionado, com distribuição normal com **média zero** e **variância  $\sigma^2$** .

# Geoestatística:

## Estimativa por combinação linear ponderada

A hipótese mais comum é chamada **estacionaridade de 2ª ordem**:

⇒ A componente determinística,  **$m(\mathbf{x})$** , é constante (não há tendências na região).

⇒ A variância das diferenças entre duas amostras depende somente da distância  **$h$**  entre elas, isto é:

$$Var[Z(x) - Z(x + h)] = E\{[Z(x) - Z(x + h)]^2\} = 2\gamma(h)$$

**$\gamma(h)$**  é chamado de semivariância.

Para mostrar a contribuição da semivariância, podemos reescrever a equação como:

$$Z(x) = m(x) + \gamma(h) + \varepsilon''$$

Em outras palavras, como supomos  **$m(\mathbf{x})$**  ser constante, a variação local das amostras (e seu relacionamento espacial) pode ser caracterizado pela semivariância  **$\gamma(h)$** .

# Geoestatística:


## VARIOGRAMA (SEMI VARIOGRAMA)

Quando a amostragem envolve duas direções  $(x,y)$  o instrumento mais indicado na estimativa da dependência entre amostras é o variograma (Silva, 1988).

O variograma é uma ferramenta básica de suporte às técnicas de *krigagem*, que permite representar, quantitativamente, a variação de um fenômeno regionalizado no espaço (Huijbregts, 1975).

Considere duas variáveis regionalizadas,  $X$  e  $Y$ , onde  $X=Z(x)$  e  $Y=Z(x+h)$ .

Neste caso, referem-se ao mesmo atributo (por exemplo, teor de zinco no solo) medido em duas posições diferentes, onde  $x$  denota uma posição de duas dimensões, com componentes  $(x,y)$ , e  $h$  um vetor distância (módulo e direção) que separa os pontos.



# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

O **nível de dependência** entre essas duas variáveis regionalizadas,  $X$  e  $Y$ , é **representado pelo variograma**,  $2\gamma(h)$ , o qual é definido como a **esperança matemática do quadrado da diferença entre os valores de pontos no espaço, separados pelo vetor de distância  $h$** , isto é,

$$2\gamma(h) = E\{[Z(x) - Z(x + h)]^2\} = Var[Z(x) - Z(x + h)]$$

Através de uma amostra  $z(x_i)$ ,  $i = 1, 2, \dots, n$ , o variograma pode ser estimado por:

$$2\hat{\gamma}(h) = \frac{1}{N(h)} \sum_{i=1}^{N(h)} [Z(x_i) - Z(x_i + h)]^2$$

onde:  $2\hat{\gamma}(h)$  é o variograma estimado;

$N(h)$  é o número de pares de valores medidos,  $z(x_i)$  e  $z(x_i + h)$ , separados por um vetor distância  $h$ ;

$z(x_i)$  e  $z(x_i + h)$  são valores de  $i$ -ésima observação da variável regionalizada, coletados nos pontos  $x_i$  e  $x_i + h$  ( $i = 1, 2, \dots, n$ ), separados pelo vetor  $h$ .

# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

O variograma é função do vetor  $h$  (módulo e direção).

$$\gamma(h) = \frac{1}{2N(h)} \sum [v_i - v_j]^2$$

Essa equação é também definida como *semivariograma*, porque é dividida por 2.

Para efeito prático, tratar-se-á *variograma* e *semivariograma* com o mesmo significado.


O variograma normalmente atinge o patamar, chamado de ***sill***, o qual é aproximadamente igual a variância total dos valores amostrais (a variância a priori dos dados).

A distância em que o variograma alcança o patamar é chamado alcance (***range***).

# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

Embora o variograma deva passar pela origem  $\gamma(0)=0$ , frequentemente ele aparece cortando o eixo vertical em um valor positivo, chamado efeito pepita (*nugget effect*).



Variograma ideal.




# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

### Parâmetros do variograma

O seu padrão represente o que, intuitivamente, se espera de dados de campo, isto é, que as diferenças  $\{Z(x_i) - Z(x_i + h)\}$  decresçam, a medida que  $h$ , a distância que os separa, decresce.



É esperado que observações mais próximas geograficamente tenha um comportamento mais semelhante entre si do que aquelas separadas por maiores distâncias.

$\gamma(h)$  aumenta com a distância  $h$ .

# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

**Alcance ( $a$ ):** distância, dentro da qual, as amostras apresentam-se correlacionadas espacialmente.

**Patamar ( $C$ ):** é o valor do variograma correspondente a seu *alcance* ( $a$ ).

Desse ponto em diante, considera-se que não existe mais dependência espacial entre as amostras, porque a variância da diferença entre pares de amostras torna-se invariante com a distância.

**Efeito Pepita ( $C_0$ ):** idealmente igual a zero.

Entretanto, na prática, à medida que  $h$  tende a 0 (zero),  $\gamma(h)$  se aproxima de um valor positivo, ( $C_0$ ), que revela a descontinuidade do semivariograma para distâncias menores do que a menor distância entre as amostras.

Parte desta descontinuidade pode ser também devida a erros de medição (Isaaks; Srivastava, 1989).

# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

**Contribuição ( $C_1$ ):** é a diferença entre o patamar ( $C$ ) e o efeito pepita ( $C_0$ ).

### Cálculo do semivariograma para amostras regularmente espaçadas

Para determinar o semivariograma experimental, por exemplo, na direção de  $90^\circ$ , o cálculo de  $\hat{\gamma}(h)$  é repetido para todos os intervalos de  $h$ .

Suponha a distância entre dois pontos consecutivos igual a 100m.

Então, qualquer par de observações, na direção de  $90^\circ$ , cuja distância é igual a 100m, será incluído no cálculo de  $\hat{\gamma}(h)$  ( $90^\circ, 100m$ ).

Isto feito, os cálculos são repetidos para a próxima distância, por exemplo, 200m.


Isso inclui todos os pares de pontos, cuja distância é igual a 200m.

# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

### Cálculo do semivariograma para amostras regularmente espaçadas

O processo é repetido até que algum ponto de parada desejado seja alcançado.



# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

Cálculo do semivariograma para amostras regularmente espaçadas




Ilustração para o cálculo do semivariograma a partir de uma malha de amostragem regularmente espaçada.


# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

**Cálculo do semivariograma a partir de uma malha de amostragem irregularmente espaçada.**

Neste caso é necessário introduzir limites de tolerância para direção e distância.

Tome como referência o Lag2 da figura.



# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

### Cálculo do semivariograma a partir de uma malha de amostragem irregularmente espaçada

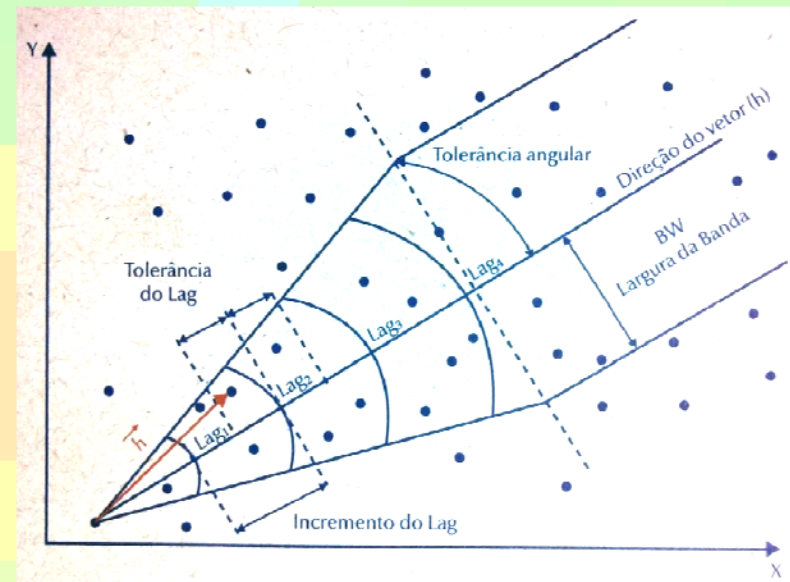
*Lag refere-se a uma distância pré-definida, a qual é utilizada no cálculo do semivariograma.*

Suponha um incremento de Lag igual a 100m com tolerância de 50m.

Considere ainda a direção de medida de  $45^\circ$  com tolerância angular de  $22,5^\circ$ .

Então, qualquer par de observações cuja distância está compreendida entre 150m e 250m e  $22,5^\circ$  e  $67,5^\circ$  será incluído no cálculo do semivariograma de Lag2.

Este processo se repete par todos os Lags.



# **Geoestatística:**

## **VARIOGRAMA (SEMIVARIOGRAMA)**

### **Cálculo do semivariograma a partir de uma malha de amostragem irregularmente espaçada**

A largura da banda (BW) se refere a um valor de ajuste a partir do qual se restringe o número de pares de observações para o cálculo do semivariograma.

A próxima etapa constitui o ajuste de um modelo teórico ao semivariograma experimental.



# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

### Modelos de Semivariogramas (Variogramas)

O ajuste de um modelo teórico ao semivariograma experimental não é direto e automático, pois, nesse processo, o intérprete faz um primeiro ajuste e verifica a adequação do modelo teórico.

Dependendo do ajuste obtido, pode ou não redefinir o modelo, até obter um que seja considerado satisfatório.

Os modelos podem ser de dois tipos: **modelos com patamar** e **modelos sem patamar**.

Os **modelos com patamar** são conhecidos como **modelos transitivos**.

Alguns modelos transitivos atingem o patamar (C) assintoticamente, onde o alcance (a) é arbitrariamente definido como a distância correspondente a 95% do patamar.

# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

### Modelos de Semivariogramas (Variogramas)

Os **modelos sem patamar** continuam aumentando enquanto a distância aumenta.

Tais modelos são utilizados para modelar fenômenos que possuam capacidade infinita de dispersão (**modelo potência**).

Os **modelos transitivos** mais utilizados são:

- *Modelo esférico (Sph);*
- *Modelo Exponencial (Exp); e*
- *Modelo Gaussiano.*

# **Geoestatística:**

## **VARIOGRAMA (SEMIVARIOGRAMA)**

### **Modelos de Semivariogramas (Variogramas)**

#### **Modelo esférico (Sph)**

O modelo esférico é um dos modelos mais utilizados e a equação normalizada é:

$$\begin{cases} \gamma(h) = C_0 + C \left[ 1,5 \frac{h}{a} - 0,5 \left( \frac{h}{a} \right)^3 \right] & \text{para } h < a \\ \gamma(h) = C_0 + C & \text{para } h \geq a \end{cases}$$

Para dados ambientais é aplicado em 95% dos casos.

# **Geoestatística:**

## **VARIOGRAMA (SEMI VARIOGRAMA)**

### **Modelos de Semivariogramas (Variogramas)**

#### **Modelo exponencial (Exp)**

A equação normalizada é:

$$\gamma(h) = C_0 + C \left[ 1 - \exp\left(-\frac{h}{a}\right) \right]$$

Esse modelo atinge o patamar assintoticamente, com alcance prático definido como a distância na qual o valor do modelo é 95% do patamar (Isaaks; Srivastava, 1989).

# **Geoestatística:**

## **VARIOGRAMA (SEMI VARIOGRAMA)**

### **Modelos de Semivariogramas (Variogramas)**

#### **Modelo gaussiano (Gau)**

É um modelo transitivo, muitas vezes, usada para modelar fenômenos extremamente contínuos. Sua formulação é dada por:

$$\gamma(h) = C_0 + C \left[ 1 - \exp \left( - \left( \frac{h}{a} \right)^2 \right) \right]$$

Esse modelo também atinge o patamar assintoticamente, com alcance prático definido como a distância na qual o valor do modelo é 95% do patamar (Isaaks; Srivastava, 1989).

O que caracteriza esse modelo é seu comportamento parabólico próximo à origem.

# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

### Modelos de Semivariogramas (Variogramas)

#### Linear

Sua formulação é dada por:

$$\gamma(h) = \begin{cases} C_0 + \frac{C}{a}h & \text{para } h \leq a \\ C_0 + C & \text{para } h > a \end{cases}$$

Neste modelo o patamar é determinado por inspeção.

O coeficiente angular  $C/a$  é determinado pela inclinação da reta que passa pelos primeiros pontos de  $\gamma(\mathbf{h})$  dando-se maior peso àqueles que correspondem a maior número de pares.

# **Geoestatística:**

## **VARIOGRAMA (SEMI VARIOGRAMA)**

### **Modelos de Semivariogramas (Variogramas)**

#### **Modelo cúbico**

$$\begin{cases} \gamma(h) = C_0 + C \left[ 7 \left( \frac{h}{a} \right)^2 - \frac{35}{4} \left( \frac{h}{a} \right)^3 + \frac{7}{2} \left( \frac{h}{a} \right)^5 - \frac{3}{4} \left( \frac{h}{a} \right)^7 \right] & \text{para } h < a \\ \gamma(h) = C_0 + C & \text{para } h \geq a \end{cases}$$

#### **Modelo Pentaesférico**

$$\begin{cases} \gamma(h) = C_0 + C \left[ \frac{15}{8} \left( \frac{h}{a} \right) - \frac{5}{4} \left( \frac{h}{a} \right)^3 + \frac{3}{8} \left( \frac{h}{a} \right)^5 \right] & \text{para } h < a \\ \gamma(h) = C_0 + C & \text{para } h \geq a \end{cases}$$

# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

### Modelos de Semivariogramas (Variogramas)

#### Modelo efeito furo (*hole effect*)

$$\gamma(h) = C_0 + C \left[ 1 - \frac{\sin \pi \frac{h}{a}}{\pi \frac{h}{a}} \right]$$

#### Modelo potência

O modelo potência não é um modelo transitivo, portanto não atinge o patamar.

$$\gamma(h) = C_0 + \alpha[h]^\beta$$

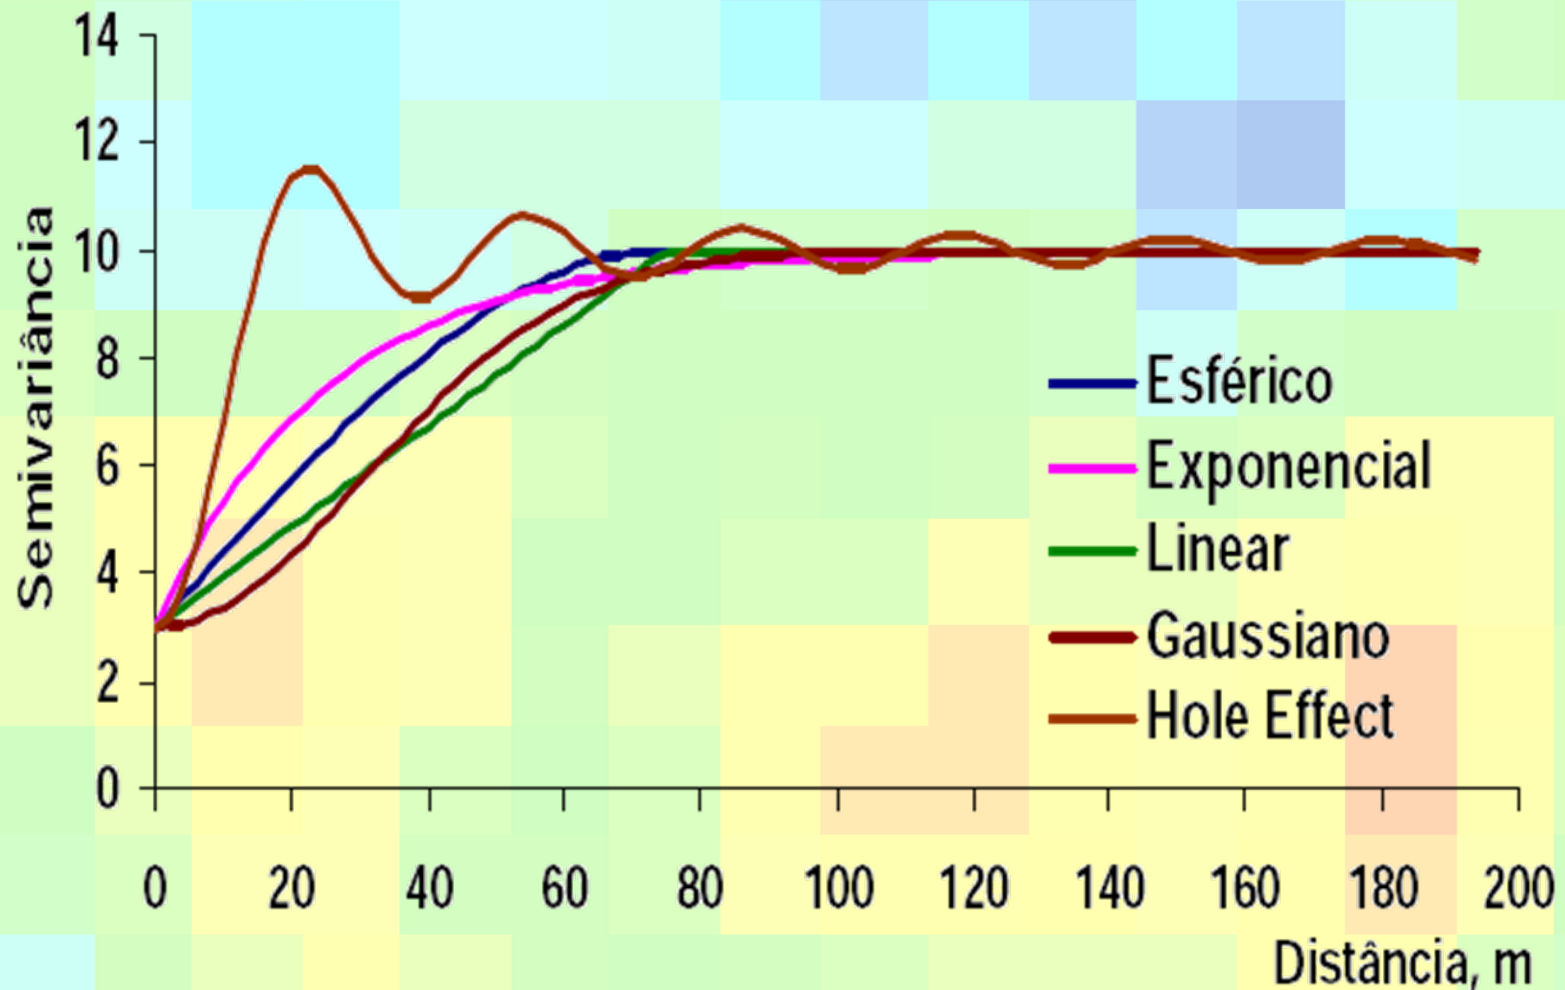
$\alpha$  representa uma constante positiva que multiplica a distância elevada a uma potência  $\beta$ .



# Geoestatística:

## VARIOGRAMA (SEMI VARIOGRAMA)

### Modelos de Semivariogramas (Variogramas)



# Geoestatística:

## VARIOGRAMA (SEMIVARIOGRAMA)

### Modelos de Semivariogramas (Variogramas)

#### Modelos aninhados

Os modelos aninhados são combinações de modelos simples utilizados para modelar fenômenos mais complexos.

Por exemplo, um modelo aninhado útil em estudos de mineração e pesquisa de solo é o duplo esférico, definido como:

$$\begin{cases} \gamma(h) = C_0 + C_1 \left[ 1,5 \frac{h}{a_1} - 0,5 \left( \frac{h}{a_1} \right)^3 \right] & \text{para } 0 < h \leq a_1 \\ \gamma(h) = C_0 + C_2 \left[ 1,5 \frac{h}{a_2} - 0,5 \left( \frac{h}{a_2} \right)^3 \right] & \text{para } a_1 < h \leq a_2 \\ \gamma(h) = C_0 + C_1 & \text{para } h \geq a_2 \end{cases}$$

# **Geoestatística:**

## **Grau de Dependência Espacial**

Os variogramas expressam o comportamento espacial da variável regionalizada ou de seus resíduos e mostram o tamanho da zona de influência em torno de uma amostra, a variação nas diferentes direções do terreno, indicando também continuidade da característica estudada no terreno (Landim, 1998).

Trangmar et al (1985) sugeriram o uso da % da variância do efeito pepita para mensurar a dependência espacial (IDE), sendo que Cambardella et al (1994) propuseram os seguintes intervalos para avaliar a % da variância do efeito pepita:

$IDE \leq 25\%$  = forte dependência espacial;

$25\% \leq IDE \leq 75\%$  = moderada dependência espacial;

$\geq 75\%$  = fraca dependência espacial.

$$IDE = \frac{C_0}{(C_0 + C_1)} \times 100$$

# **Geoestatística:**

## **Grau de Dependência Espacial**

Zimback (2001) propôs a inversão dos fatores, como:

$$IDE = \frac{C_1}{(C_0 + C_1)} \times 100$$

e a classificação quanto ao grau de dependência espacial da variável em estudo é:

- i) variável independente espacialmente – se a relação entre a componente estrutural e o patamar for igual a 0%, neste caso o variograma será com efeito pepita puro;
- ii) variável com fraca dependência espacial – se a componente estrutural for menor ou igual a 25% do patamar;
- iii) Variável com moderada dependência espacial – se a componente estrutural estiver entre 25% e 75% do patamar;
- iv) Variável com forte dependência espacial – se a relação entre a componente estrutural e o patamar for maior ou igual 75%.